# Sensitivity Is Not Fragility:
# Shared Visual Responses in Vision-Language-Action Policies

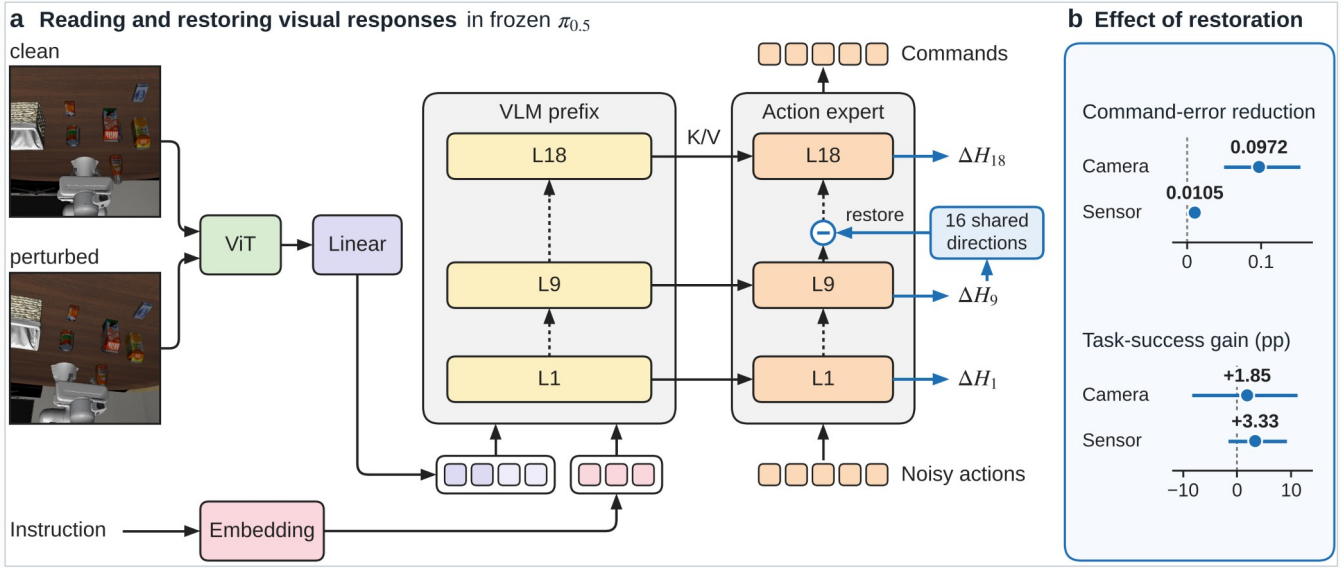
视觉 - 语言 - 动作策略中的共享视觉响应

[Jinwen He]

组会汇报 · 2026 年 11 月 12 日 · CVPR 2027 投稿稿件

# Sensitivity Is Not Fragility ｜全文概览

> **核心贡献：**我们在冻结的 π0.5 中发现了可跨任务与扰动类别复用的共享视觉响应，在生成过程中恢复这些成分无需重训即可修正动作指令；执行研究进一步表明，动作与运动偏差的大小并不直接决定任务成败。




## 研究问题

1. 不同视觉扰动是否引起共享的内部响应?
2. 在生成过程中恢复这些响应，能否修正动作?
3. 动作变化对运动和任务结果意味着什么?

## 研究设置

- LIBERO 微调后冻结的 π0.5 与 π0，不做训练
- LIBERO-Plus 四类扰动： Background 、 Camera 、 Light 、 Sensor Noise
- 三项配对研究：内部记录 404 对；原生恢复 216 对（31 个独立任务）；配对执行每个策略 202 个 settings

### 发现 1 ｜共享响应（§4.1–4.2）

- 16 个共享方向在联合留出的任务与扰动类别上保留 36.5–83.6% 的响应能量，同秩 clean / 随机方向不超过 10.2%
- L1 最适合重建响应， L18 最适合预测指令变化

### 发现 2 ｜内部恢复（§4.3）

- 在 L9 恢复 16 维共享坐标，指令误差 Camera 0.409 → 0.312 、 Sensor 0.209 → 0.199 ， 6 项同时区间均为正
- 观测成功率高 1.85 / 3.33 个百分点，区间包含 0

### 发现 3 ｜执行后果（§5）

- 初始指令变化与早期运动的秩相关为 0.95–0.97 ，重规划后降至 0.41–0.47
- π0 在 Sensor Noise 下运动仅为 clean 重采样差异的 0.58 倍，成功率仍下降 14.3 个百分点；净成功率不变也可能掩盖结果翻转

# 1 引言：研究背景与动机

- 背景、视角、光照等视觉变化不改变任务本身，却显著影响 VLA 的行为。 LIBERO-Plus 报告 π0 的成功率由原始 LIBERO 上的 94.2% 降至相机扰动下的 13.8% 。
- 然而，动作偏差的大小并不能直接说明任务后果。我们的实验中观察到两种相反的情形：

| 设定 | 动作 / 运动的偏差 | 任务结果 |
| --- | --- | --- |
| π0.5 ， Light | 两种扰动下，前 5 条平移指令的平均偏差相差 5.12 倍 | 两种扰动与无扰动均为 77/80 次成功 |
| π0 ， Sensor Noise | 平均早期运动偏差小于两次无扰动运行之间的差异 | 成功率下降 14.3 个百分点 |

- 本文用 sensitivity 描述内部特征、动作指令或运动的变化，用 fragility 描述任务成功率的下降，二者需要分别测量。

# 1 引言：研究问题与思路

**本文围绕三个问题展开：**

1. 不同视觉扰动是否在模型内部引起共享的响应?
2. 恢复这些响应，能否修正策略生成的动作?
3. 动作变化对机器人运动和任务结果意味着什么?

**研究思路：**

- 从扰动引起的特征差异中学习共享方向，并在拟合时未出现的任务与扰动类别上检验其复用（第 4.1–4.2 节）
- 利用同一物理状态的无扰动观测恢复这些方向上的坐标，检验能否修正策略自身的输出，并记录任务成功率（第 4.3 节）
- 在独立的执行研究中，比较有无扰动时的动作指令、机器人运动与任务结果（第 5 节）

研究对象： LIBERO 微调后冻结的 π0.5 与 π0； LIBERO / LIBERO-Plus 中的 Background 、 Camera 、 Light 、 Sensor Noise 四类扰动。

# 2 相关工作

- **VLA 的视觉鲁棒性：** LIBERO-Plus 系统评测背景、视角、光照与传感器噪声等变化，发现成功率大幅下降； BYOVLA 在部署时编辑与任务无关的图像区域， RoVLA 在训练中鼓励观测与指令变化下的一致预测。
- **VLA 的机制分析：** VLA-Trace 追踪表征并干预注意力； Wulff et al. 用 activation patching 研究语言 grounding ； Zhang et al. 将干预式视觉归因与泛化联系起来； SAE 分析发现可复用、可操控的运动与语义特征； COAST 由成功与失败的 rollout 构造激活子空间以改进执行。
- **超越成功率的行为评估：** Higham et al. 刻画扰动下成功轨迹的平滑度、效率与夹爪行为； Sawada & Kasahara 比较配对执行，发现成功与失败的相反翻转会在总成功率中相互抵消。
- **本文定位：**关注视觉扰动诱发的内部变化，即哪些成分跨任务与扰动类别复用、恢复其 clean 坐标能否修正动作偏差；同时以 clean 运行之间的差异为参照比较运动，并追踪丢失与新增的成功，将敏感性与任务后果联系起来。

# 本文的主要发现与创新点

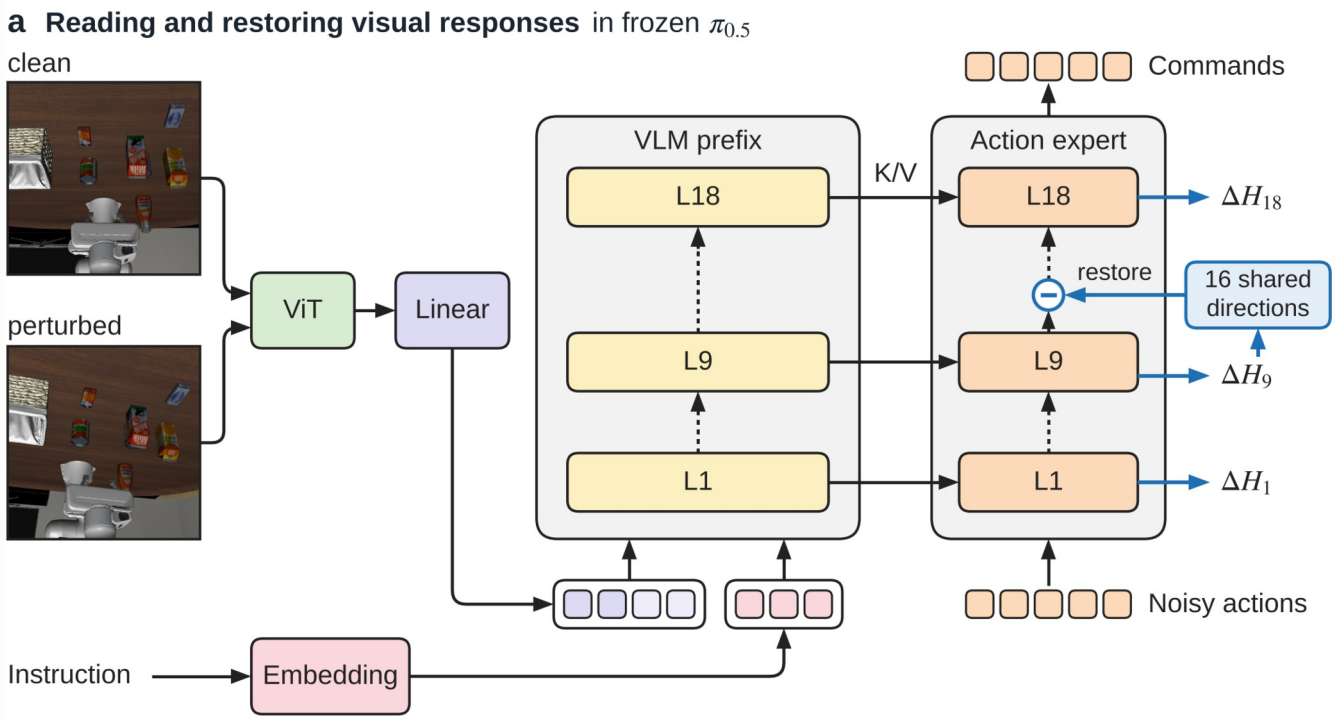
**主要发现**

1. 扰动响应的共享结构： π0.5 中 16 个共享方向在联合留出的任务与扰动类别上重建响应，优于同秩的 clean 与随机方向；响应重建与动作预测偏好不同的层。
2. 恢复共享成分修正初始指令：用同一物理状态的 clean 观测恢复共享成分，无需重训即可降低前 5 条平移指令的误差； Camera 与 Sensor 下观测成功率也更高。
3. 动作、运动与任务结果：初始指令变化紧密对应早期运动；但 π0 在 Sensor Noise 下早期运动偏差低于 clean 重采样差异，仍损失 14.3 个百分点；净成功率不变也可能掩盖相反方向的结果翻转。

**方法上的新意（在于实验设计，而非新算法）**

- 以 clean– 扰动配对差异学习方向，联合留出任务组与扰动类别，并设同秩 clean / 随机基底对照
- 在策略自身的生成过程中（每次 query 、每个生成步）进行恢复，在独立确认集上以预设终点检验
- 以 clean 重采样差异作为运动尺度的参照，分别统计丢失与新增的成功
- PCA 、 affine ridge 读出与坐标替换本身均为标准工具，不作为方法贡献

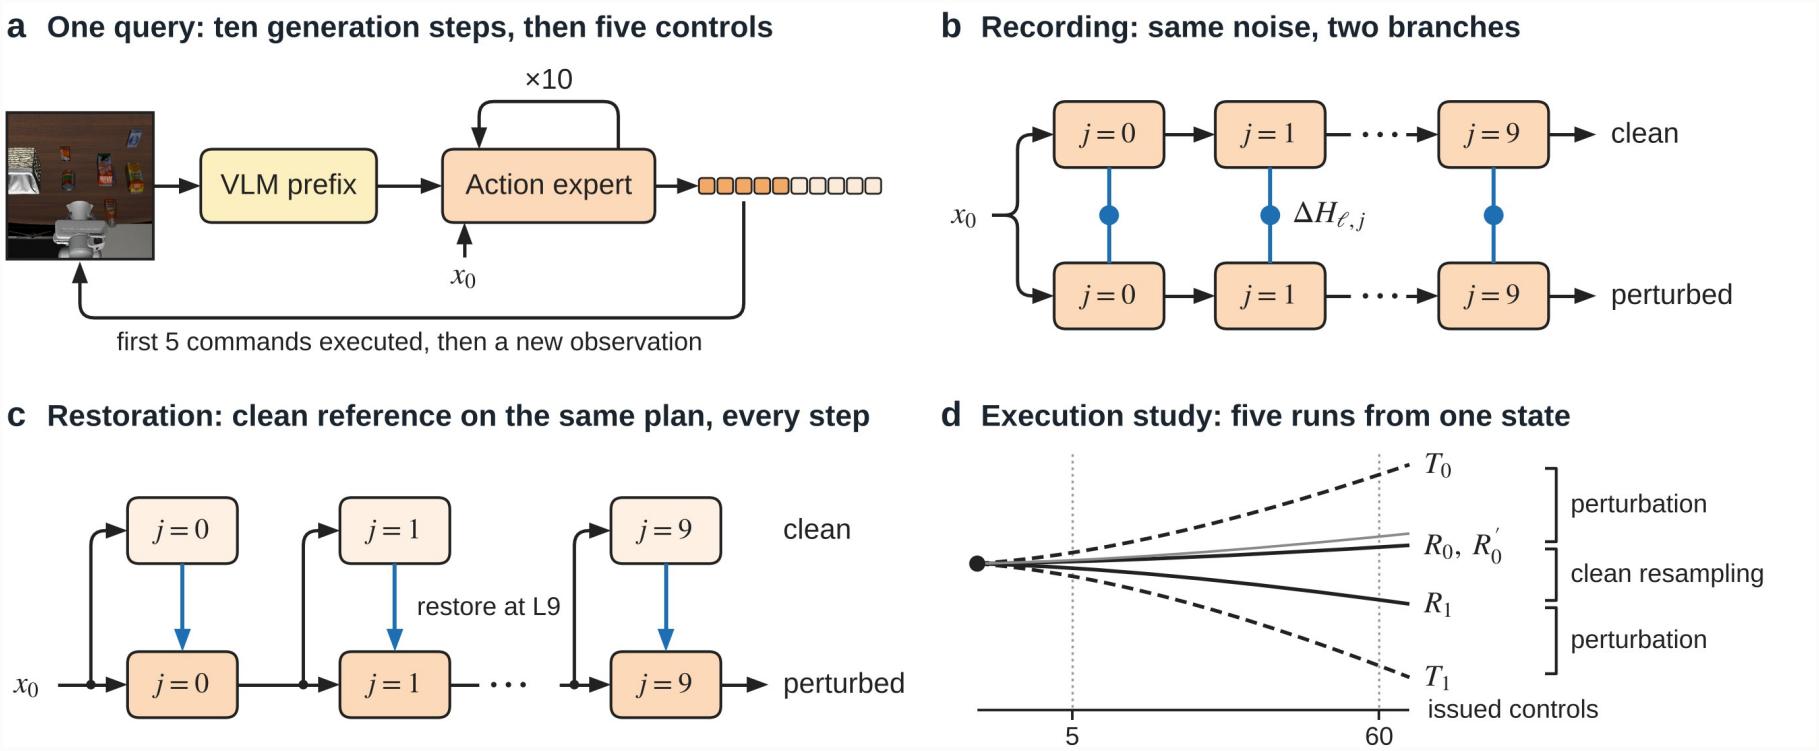
# 3.1 从观测到动作指令




论文图 1(a)： 在冻结的 π0.5 中读出与恢复视觉响应

- 每次 query， VLM 将主相机、腕部相机图像与任务指令编码为上下文 token （prefix）
- action expert 从噪声 $x_0$ 出发，以 10 步 Euler 更新生成整段动作计划（π0.5 为 10 个动作）
- 执行前 5 条指令后取新观测并重新规划；前 5 个控制只由初始计划驱动
- 在 action expert 的 L1 、 L9 、 L18 之后记录隐状态，定义响应 $\Delta H = H^p - H^c$，每层为 10 × 1024
- clean 与扰动分支共享初始噪声，之后各自更新计划

# 3.1 记录、恢复与执行的时间结构




论文图 2 。(a) 每次 query 计算一次 prefix， action expert 用 10 个 Euler 步更新整段计划，执行前 5 条指令后进入下一次 query； (b) 记录：两分支共享 $x_0$，在每个生成步与采样层取 ΔH； (c) 恢复：每个生成步在干预运行当前的状态、计划样本与生成时刻计算 clean 参照，并将其共享坐标写入 L9 之后； (d) 执行： clean 运行 R0 、 R1 与扰动运行 T0 、 T1 使用两组策略噪声， R0′ 重复 R0 。

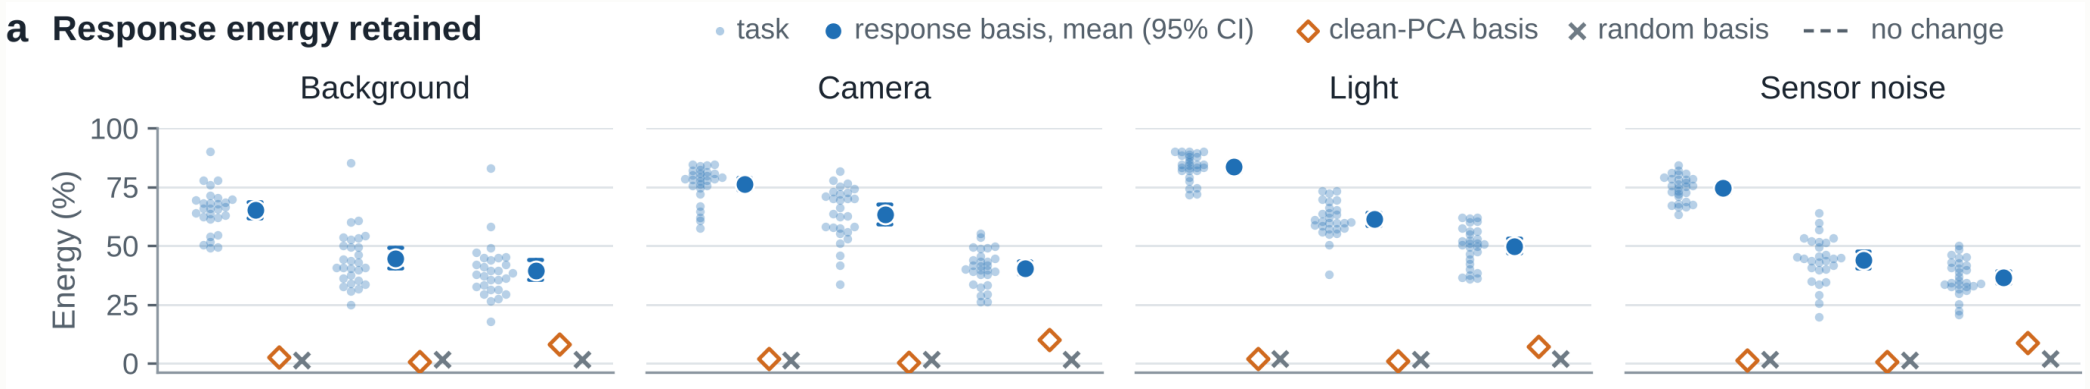
## 3.2 配对研究与比较方式

| 研究 | 评估规模 |
| --- | --- |
| 内部记录（π0.5） | 536 对 / 40 个任务；主分析 404 对 / 28 个任务（4.1–4.2 节） |
| 配对执行（π0.5 、 π0） | 每个策略 268 个 settings / 40 个任务；主分析 202 个 settings / 28 个任务（第 5 节） |
| 原生恢复（π0.5） | 独立确认集： 31 个任务， Camera 96 对、 Sensor 120 对（4.3 节） |

- setting 指一个任务在某一视觉变体下的设定。主比较使用四类扰动共有的 28 个任务上、带基准严重度标签的 202 个 LIBERO-Plus settings；每个 setting 有两组噪声匹配的 clean– 扰动配对，共 404 个内部配对。
- 执行研究中，每个 setting 在两组策略噪声下分别比较 (R0, T0) 与 (R1, T1)。两次 clean 运行 R0 、 R1 之间的差异称为 clean 重采样参照；同噪声重复 R0′ 用于检查可重复性。
- 结果先在 setting 内对噪声平均，再在任务内对 setting 平均，任务等权；抽样区间对整个任务重采样。缺失结果保留计划分母，并给出所有可能取值下的上下界。

# 4.1 共享响应跨任务与扰动类别复用

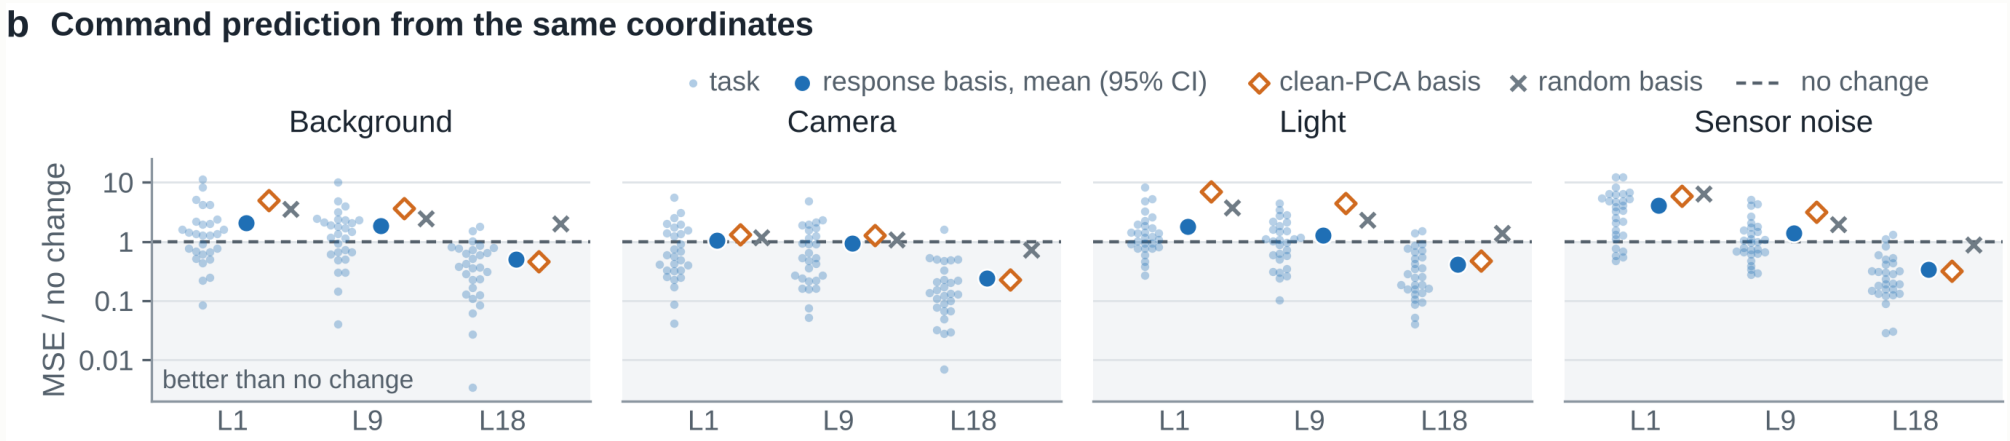
- 在首个生成步记录 404 个配对的响应 $\Delta H_i$ （i 为 10 个计划位置之一）；对每个采样层用 PCA 拟合 16 个正交方向 B （1024 × 16），并联合留出测试任务组及其扰动类别
- 重建： $\Delta\hat{H}_i = \mu_i + (\Delta H_i - \mu_i)BB^T$ ，以保留的中心化响应能量衡量；同秩的 clean-PCA 方向与随机方向作为对照
- 共享方向保留 36.5–83.6% 的响应能量， clean 方向为 0.5–10.2% ，随机方向为 1.3–1.9% ；四类扰动中均值均为 L1 最高、 L9 次之、 L18 最低
- π0 中同样存在重建优势，峰值在 L9 （补充 S15 ）




论文图 3(a)： 留出测试集上 16 个方向保留的初始步响应能量（小点为任务，大点为任务等权均值及 95% 区间）

# 4.2 响应重建与动作预测偏好不同的层

- 使用与 4.1 节相同的 404 个配对与留出方式。 affine ridge 读出由归一化的响应坐标预测首个 query 前 5 条平移指令的变化（15 维），其 MSE 除以“预测无变化”的 MSE；比值小于 1 表示优于该基线
- 各类扰动中，保留能量自 L1 至 L18 逐层下降，预测误差也逐层下降。以 Light 为例，三层保留能量为 83.6% 、 61.2% 、 49.8% ，归一化误差为 1.764 、 1.284 、 0.407
- 逐任务比较， L1 重建最好且 L18 预测最好的任务数： Background 24/28 ， Camera 26/28 ， Light 与 Sensor 各 27/28




论文图 3(b)： 由同一组坐标预测指令变化的归一化 MSE ， 阴影区域优于“预测无变化”。 L18 上 response 与 clean 坐标之差的配对区间跨 0 （补充 S3.4 、 S14 ） 。

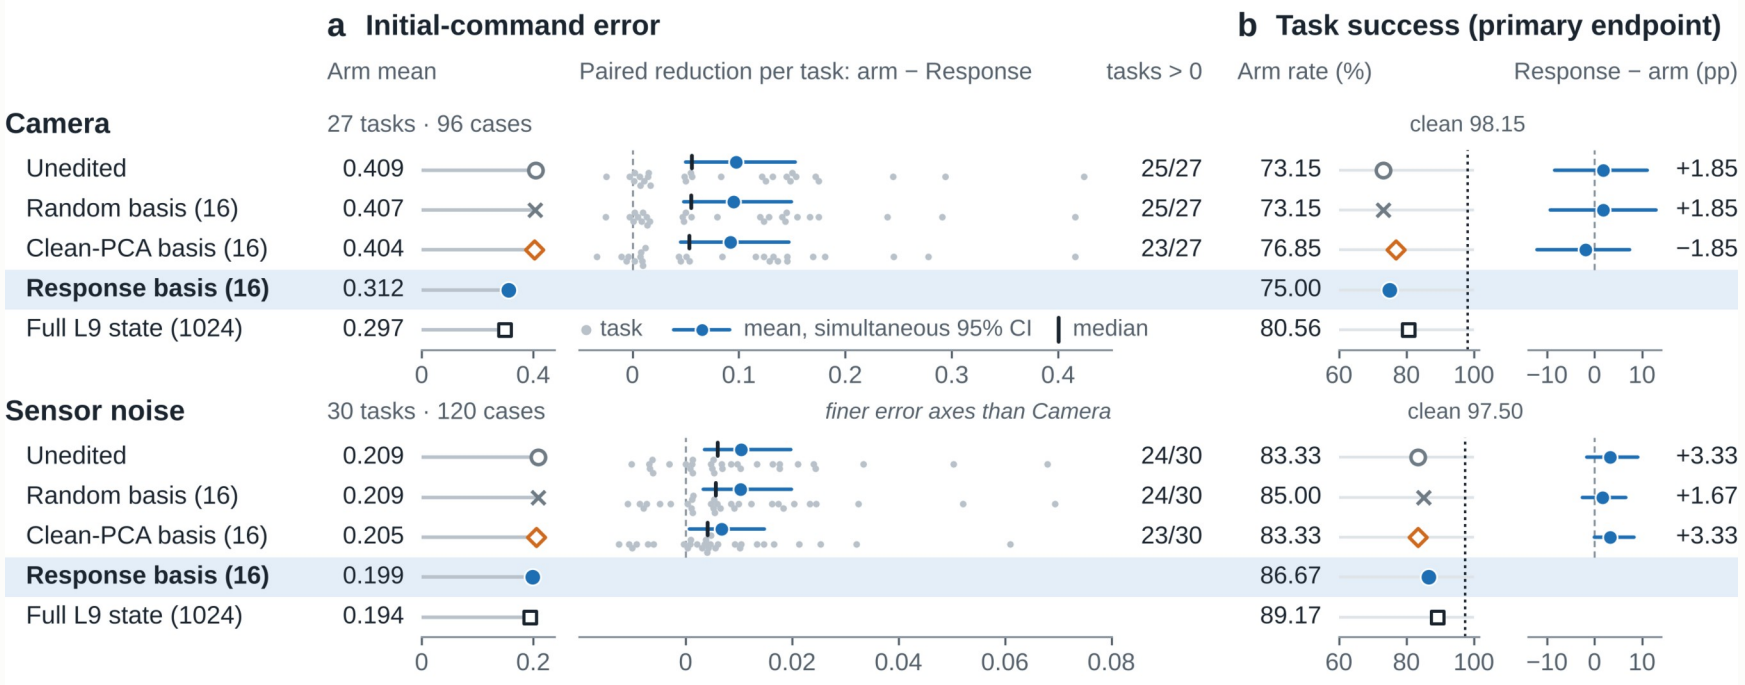
# 4.3 恢复共享成分修正动作指令：方法

- 在预先指定的 L9，把 16 个共享方向上的分量替换为同一物理状态下 clean 观测给出的值，正交分量保持不变：

$$H' = H^p - (H^p - H^c)BB^T$$

- 每次 query 在干预运行当前的状态下渲染 clean 视图； $H^c$ 与 $H^p$ 使用相同的动作计划样本与生成时刻。之后继续使用扰动的视觉上下文生成，10 个生成步全部执行。
- 独立确认研究： 31 个任务、 216 个配对（ Camera 96 、 Sensor 120 ），与 9 个开发任务不重叠。
- 主终点为任务成功率；关键次终点为首个 query 前 5 条平移指令相对配对 clean 运行的欧氏误差。
- 对照：未编辑策略；同秩 clean-PCA 方向与随机方向的恢复；完整 L9 替换（ 1024 个通道）作为参照。各基底拟合时均排除测试任务组与扰动类别，并各自写回实际的坐标差，因此写入幅度不同。
- clean 参照是实验中用于检验作用的信息，本研究不将其作为部署方案。

# 4.3 恢复共享成分修正动作指令：结果




- 指令误差： Camera 由 0.409 降至 0.312， Sensor 由 0.209 降至 0.199；相对未编辑、 clean 与随机方向恢复的 6 项同时 95% 区间均为正。完整 L9 替换为 0.297 / 0.194， 16 个方向约达到其误差降幅的 86.9% / 70.7% 。
- 任务成功率： Camera 73.15% → 75.00%， Sensor 83.33% → 86.67% （clean 基线 98.15% / 97.50%）；同时 95% 区间为 [−8.33, 11.11] 与 [−1.67, 9.17] 个百分点，均包含 0，增益大小尚未精确估计。

# 5.1 初始动作变化与早期运动

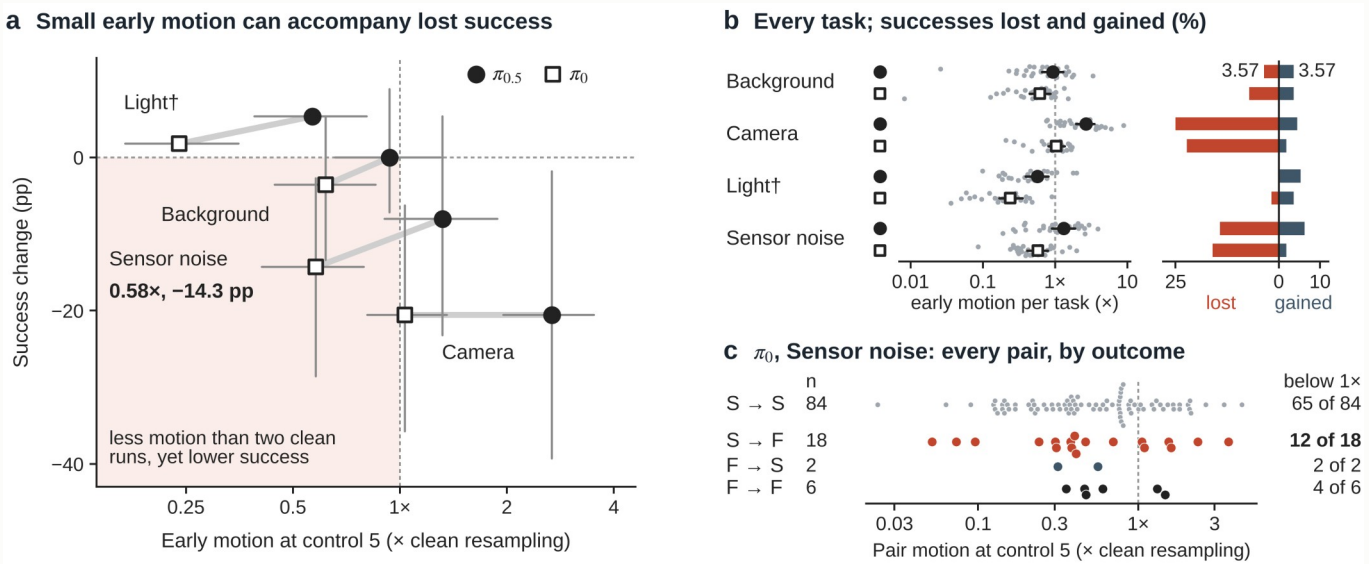
- 独立的 LIBERO-Plus 执行研究，策略不做编辑；每组比较匹配初始物理状态与策略噪声，按已执行控制数比较运动。
- 初始动作变化取前 5 条已发出平移指令之差的欧氏范数（15 维）；运动取 clean 与扰动运行末端执行器的距离，分别在第 5 与第 60 个控制后测量。第 5 个控制前尚无新观测进入，第 60 个控制时已多次重规划。

| 策略 | 控制 5 | 控制 60 | 差值（95% 区间） |
|---|---:|---:|---:|
| π0.5 | 0.953 | 0.474 | 0.479 [0.368, 0.593] |
| π0 | 0.974 | 0.409 | 0.566 [0.463, 0.671] |

初始指令变化与末端执行器距离的任务加权秩相关（完整 40 任务面板，区间为任务 bootstrap）

- 同一视觉条件在两组策略噪声下引起相近的指令偏移：一致性得分（1 表示方向与幅度均相同）在 π0.5 中为 0.884–0.920，在 π0 中为 0.799–0.889。
- 初始动作响应直接反映在早期运动中；经过后续观测与重规划，二者的关联减弱。

# 5.2 运动幅度与配对任务结果




论文图 5： (a) 第 5 个控制后的运动比与成功率变化； (b) 逐任务运动比与丢失 / 新增成功； (c) π0 Sensor Noise 下 110 个配对的逐对结果

- 以两次 clean 运行（不同策略噪声）之间的平均距离为参照；比值小于 1 表示视觉扰动带来的运动差异小于该参照。
- π0， Sensor Noise： 早期运动比 0.580 [0.409, 0.791]，成功率下降 14.3 个百分点（98.75% 区间 [−28.6, −2.7]）； 18 个丢失成功的配对中，12 个低于自身 setting 的参照。
- Camera： 两种策略估计的成功率下降均为 20.5 个百分点，早期运动比分别为 2.68 （π0.5 ）与 1.03 （π0 ）。
- π0.5， Background： 丢失与新增成功的加权比例均为 3.57%，净变化为 0，但 7.14% 的结果发生翻转。

# 6 结论与意义

## 结论

- 在 π0.5 中，扰动诱发的特征变化存在共享方向，可在留出的任务与扰动类别上描述响应；响应重建与固定仿射读出的动作预测偏好不同的采样层。
- 用同一物理状态的 clean 观测恢复共享成分，无需重训即可降低前 5 条平移指令相对 clean 参考的误差。
- 独立执行中，初始动作差异紧密对应早期运动；但早期运动偏差低于 clean 重采样参照时仍可能出现明显的成功率损失，净成功率不变也可能掩盖相反方向的结果翻转。

## 意义

- 为研究 VLA 视觉敏感性的内部修正提供可复用的共享成分，以及可在生成过程中检验的干预位置。
- 评估视觉鲁棒性（包括评估内部修正的效果）时，应同时考察动作、运动与逐次执行的结果，而不只看平均偏差或净成功率。

# 局限与后续工作

**局限**

- 恢复依赖同一物理状态的 clean 观测，属于检验手段，尚不能直接部署
- 成功率增益的同时 95% 区间包含 0，增益大小尚未精确估计
- 仅研究冻结的 π0.5 / π0 与 LIBERO 仿真；恢复仅在 L9 、Camera 与 Sensor 下检验
- Light 有部分执行结果未记录，正文仅用已记录结果，补充材料给出上下界
- 补充 S20 的注意力分析为互补现象，不作为因果解释

**投稿前待办（截止 11 月 16 日 AoE ）**

- 图 4 精简、图 3 统一样式，图 2 待反馈
- 用 Drive 上的原始表重画图 5a （逐任务散点）
- 同步补充材料中的图件引用并重新编译
- 核对 AUROC 区间与 33.492 / 34.697 mm 两处数值